

Univerza v Ljubljani
Fakulteta za *matematiko in fiziko*



Praktikum strojnega učenja v fiziki

Določanje elastičnih konstant v nematskem tekočem kristalu

Študent:
Jurij Šumak
28242057

Profesor: prof. dr. Borut Paul Kerševan
Asistent: mag. Jaka Zaplotnik

AKADEMSKO LETO 2025/2026

1 Uvod


V tej nalogi preučujemo možnosti uporabe nevronske mreže pri analizi intenzitetnih krivulj, ki opisujejo časovni razvoj direktorskega polja v nematskem tekočem kristalu. Cilj pristopa je določiti elastične konstante iz simuliranih optičnih odzivov ter razumeti, kako na natančnost napovedi vplivajo različni dejavniki, kot so kakovost podatkov, šum, časovna ločljivost in izbira robnih pogojev.

Ker gre za problem, kjer neposredna inverzna rešitev ni trivialna, je strojno učenje učinkovit način za iskanje nelinearnih povezav med vhodnimi intenzitetami in fizikalnimi parametri sistema. V okviru naloge postopoma razvijamo in optimiziramo modele, preučujemo njihove omejitve ter ocenjujemo, v katerih primerih se mreža dobro nauči zakonitosti in kje začne odpovedovati.

2 Naloga

2.1 Analiza podatkovnega seta in časovnega razvoja


V prvem delu naloge smo se najprej seznanili s podatkovnim setom, ki vsebuje simulirane intenzitetne krivulje $I(t)$ za različne vrednosti elastične konstante K ter pripadajoče začetne direktorske profile $\theta_0(z)$. Porazdelitev uporabljenih vrednosti konstante je prikazana na sliki 1. Razvidno je, da so vrednosti razporejene v izjemno širokem območju – od zelo majhnih ($\sim 10^{-18}$) do fizikalno realističnih vrednosti za nematske tekoče kristale ($\sim 10^{-11}$). Zaradi tako velikega razpona se časovni razvoj sistema med posameznimi primeri bistveno razlikuje.



Slika 1: Porazdelitev simuliranih vrednosti konstante K .

Na sliki 2 so prikazane intenzitetne krivulje za nekaj reprezentativnih vrednosti konstante K . Pri zelo majhnih vrednostih je $I(t)$ skoraj povsem ploska funkcija časa, kar pomeni, da se direktorsko polje praktično ne relaksira. Za realistične vrednosti $K \sim 10^{-11}$

pa so časovne spremembe izrazitejše in signal vsebuje bolj informativne značilnosti, ki jih lahko kasneje izkoristimo pri učenju nevronske mreže.



Slika 2: Primerjava intenzitetnih krivulj za različne vrednosti konstante K .


Podrobnejši vpogled daje slika 3, kjer sta za posamezne vrednosti K prikazana tako intenzitetni potek $I(t)$ kot časovna evolucija direktorskega profila $\theta(z, t)$. Vidimo lahko, da:

- pri zelo majhnih K (10^{-18}) direktorski profil skoraj ne evoluiira, celotna rešitev ostaja blizu začetnemu profilu $\theta_0(z)$;
- za srednje vrednosti K je relaksacija počasnejša, profil se postopno zgladi in izgubi lokalne značilnosti;
- pri največjih K je dinamika najhitrejša, sistem se stabilizira v skoraj uniformno konfiguracijo že na kratki časovni skali.

Ker relaksacija poteka v skladu z izrazom

$$\frac{\partial \theta}{\partial t} = \frac{K}{\gamma_1} \frac{\partial^2 \theta}{\partial z^2},$$

je ob upoštevanju $\gamma_1 = 0,098 \text{ Pa} \cdot \text{s}$ je razvidno, da majhne vrednosti K vodijo v izjemno počasno dinamiko, medtem ko pri večjih vrednostih K drugi odvod postane pomemben in sistem hitro teži k energijsko ugodnejši konfiguraciji. To se neposredno odraža tudi v obliki intenzitetnih krivulj.



Slika 3: Časovni razvoj intenzitetnih signalov in pripadajočih direktorskih profilov $\theta(z, t)$ za izbrane vrednosti konstante K .


Analiza pokaže, da največja odstopanja od »tipičnih« intenzitetnih krivulj pripadajo primerom z izjemno majhnimi vrednostmi konstante K , pri katerih sistem praktično ne relaksira. Takšni primeri so zato tudi pri kasnejšem učenju nevronske mreže prepoznani kot problematični oziroma izstopajoči.

2.2 Vpliv hiperparametrov na učenje nevronske mreže

V drugem delu naloge smo preučili, kako izbira različnih hiperparametrov vpliva na natančnost in stabilnost učenja nevronske mreže, katere cilj je napovedovanje elastične konstante K iz intenzitetnih krivulj. Posebej smo se osredotočili na aktivacijske funkcije, velikost učnega koraka, velikost učnega paketa in število nevronov v skritih slojih. V nadaljevanju so predstavljeni rezultati posameznih eksperimentov.

2.2.1 Vpliv aktivacijske funkcije


Na sliki 4 primerjamo potek učenja za različne aktivacijske funkcije (ReLU, tanh, sigmoid in linearno funkcijo). ReLU, tanh in sigmoid se izkažejo za najbolj stabilne izbire, medtem ko linearna aktivacija pogosto vodi do počasnejšega učenja ali k slabšega minimuma.



Slika 4: Primerjava različnih aktivacijskih funkcij pri učenju mreže.

2.2.2 Vpliv velikosti učnega paketa


Na sliki 5 je prikazan vpliv velikosti učnega paketa. Optimalna vrednost je kompromis med stabilnostjo in hitrostjo učenja.



Slika 5: Vpliv velikosti učnega paketa na učenje nevronske mreže.

2.2.3 Vpliv učnega koraka (learning rate)


Slika 6 prikazuje rezultate za različne vrednosti učnega koraka. Prevelik učni korak (10^{-2}) povzroča oscilacije in nestabilnost, medtem ko premajhen korak (10^{-4}) vodi do zelo počasnega učenja.



Slika 6: Vpliv učnega koraka (learning rate) na potek učenja.

2.2.4 Vpliv števila nevronov v skritih slojih

Na sliki 7 je prikazan vpliv števila nevronov v posameznem skritem sloju. Manjša omrežja (32 ali 64 nevronov) se lahko hitro podučijo, medtem ko večja omrežja (128 ali 256 nevronov) bolje zajamejo nelinearne značilnosti podatkov. Preveliko število nevronov pa lahko podaljša čas učenja in poveča tveganje prenaučenosti.




Slika 7: Vpliv števila nevronov na kakovost učenja mreže.

2.3 Primerjava pravih in napovedanih vrednosti konstante K

V tretjem delu naloge smo preučili učinkovitost nevronske mreže pri napovedovanju elastične konstante K na podatkih, ki jih mreža med učenjem ni videla. Namen tega koraka je preveriti, ali se model dobro posploši na nove intenzitetne krivulje in ali se pojavljajo sistematična odstopanja za določene tipe signalov.

Na sliki 8 je prikazan dvodimenzionalni histogram, ki primerja prave in napovedane vrednosti konstante K za testni podatkovni set. Idealni model bi vse točke postavil na diagonalo $K_{\text{pred}} = K_{\text{true}}$, medtem ko odstopanja od diagonale nakazujejo na pod- ali prenapovedovanje.



Slika 8: Primerjava pravih in napovedanih vrednosti konstante K na testnem podatkovnem setu. Barve predstavljajo gostoto napovedi.

Iz slike je razvidno, da se večina testnih primerov dobro poravnava z diagonalo, kar pomeni, da model dokaj natančno napove konstanto K . Kljub temu so opazna značilna sistematična odstopanja pri zelo majhnih vrednostih $K \lesssim 10^{-14}$. V tem območju je napovedana vrednost praviloma večja od prave, kar kaže, da mreža težko razlikuje med zelo počasnimi relaksacijami, kjer je signal $I(t)$ skoraj konstanten.

2.4 Optimizacija hiperparametrov z mrežnim iskanjem in navzkrižno validacijo

V tem delu naloge smo uporabili navzkrižno validacijo in mrežno iskanje (GridSearchCV), da smo sistematično preučili vpliv različnih hiperparametrov na natančnost napovedovanja konstante K . Ker gre za problem z nelinearno povezavo med intenzivnimi krivuljami in elastičnimi konstantami, ima izbira hiperparametrov velik vpliv na stabilnost učenja in splošno sposobnost modela.

2.4.1 Priprava podatkov

Najprej smo normalizirali vhodne intenzitetne krivulje $I(t)$ z uporabo `StandardScaler`, tarčne vrednosti K pa smo skalirali s faktorjem 10^{-11} zaradi njihove izjemno majhne velikosti. To omogoča stabilno učenje in preprečuje numerične težave pri optimizaciji.

2.4.2 Model in iskalni prostor

Za iskanje optimalnih nastavitev smo pripravili funkcijo `build_model`, ki ustvari nevronske mreže z dvema skritima slojema (128 in 64 nevronov) ter omogoča izbiro naslednjih hiperparametrov:

- aktivacijska funkcija (ReLU, tanh),
- optimizator (Adam ali SGD),
- učni korak (10^{-2} , 10^{-3} ali 10^{-4}),
- moment pri SGD (0, 0.5, 0.9),
- velikost učnega paketa (32, 64, 128),
- število epoh (40, 80, 120).

Pri optimizatorju SGD smo vključili tudi eksponentni razpad učnega koraka (`keras.optimizers.schedules.ExponentialDecay`), kot zahtevajo navodila. Tako smo lahko preverili, ali se s pravilno nastavljenim SGD lahko približamo učinkovitosti optimizatorja Adam.

2.4.3 Mrežno iskanje in navzkrižna validacija

Za iskanje optimalne kombinacije hiperparametrov smo uporabili:

- 5-kratno navzkrižno validacijo (KFold z $k = 5$),
- `GridSearchCV` iz knjižnice `scikit-learn`,
- `KerasRegressor` iz knjižnice `SciKeras`, ki omogoča integracijo TensorFlow modela v okolje `sklearn`.

Vsaka kombinacija hiperparametrov se je trenirala petkrat, kar omogoča zanesljivo oceno generalizacijske napake. Zaradi velikega števila kombinacij je postopek zelo računsko zahteven (več kot 1500 treniranj modela), kar se je odrazilo tudi v dolgem času izvajanja.

2.4.4 Najboljši model

Po zaključenem mrežnem iskanju smo pridobili optimalni sklop hiperparametrov, ki se je izkazal za najučinkovitejšega v povprečju vseh validacijskih sklopov. Najboljši model je bil izbran na podlagi najmanjše validacijske napake (MSE), pri čemer je dosegel vrednost


$$\text{Best score} = -0.0253.$$

Optimalni hiperparametri, dobljeni z mrežnim iskanjem, so:

- velikost učnega paketa: **128**,
- število epoh: **80**,
- aktivacijska funkcija: **ReLU**,
- učni korak: 10^{-3} ,
- momentum: **0,9**,
- uporabljen optimizator: **Adam**.

S temi parametri smo model ponovno natrenirali na celotnem učnem naboru, kar je omogočilo najbolj stabilno in natančno napovedovanje konstante K med vsemi testiranimi konfiguracijami.

Na sliki 9 je prikazan potek učenja najboljšega modela. Vidimo, da validacijska napaka sledi učni napaki, kar pomeni, da je izbira hiperparametrov uspešna.



Slika 9: Potek učenja najboljšega modela, dobljenega z mrežnim iskanjem in 5-kratno navzkrižno validacijo.


2.5 Vpliv šuma na natančnost napovedovanja konstante K

V petem delu naloge smo preučili, kako dodan beli šum v intenzitetnih krivuljah vpliva na zmožnost nevronske mreže, da pravilno napove elastično konstanto K . Za ta namen smo uporabili dva podatkovna seta: enega brez šuma in enega z dodanim šumom amplitude 100. Analizirali smo tri scenarije učenja: (i) učenje in testiranje brez šuma, (ii) učenje in testiranje s šumom ter (iii) učenje brez šuma, testiranje pa na šumnih podatkih.

2.5.1 Primerjava napak med različnimi scenariji

Na sliki 10 so prikazane porazdelitve napak ($K_{\text{pred}} - K_{\text{true}}$) za vse tri primere. Rezultati kažejo:

- **Trening brez šuma → testi brez šuma:** napake so najmanjše, porazdelitev je ozka in simetrična okoli ničle. To je pričakovano, saj so vhodni podatki gladki, brez stohastičnih motenj.
- **Trening s šumom → testi s šumom:** napaka se nekoliko poveča, vendar je model še vedno sposoben prepoznati ključne značilnosti intenzitetnih krivulj.
- **Trening brez šuma → testi s šumom:** to je najslabši primer. Mreža tukaj ni bila izpostavljena motnjam med učenjem, zato poskuša interpretirati šum kot fizikalno informacijo. To vodi do sistematičnega odstopanja, pri katerem so napovedi pogosto pristranske.



Slika 10: Porazdelitev napak pri napovedovanju konstante K za tri različne scenarije učenja in testiranja. Označena je razlika med učenjem z in brez šuma.


2.6 Vpliv časovne ločljivosti in izsekov intenzitetnih krivulj

V šestem delu naloge smo preučili, kako na uspešnost napovedovanja konstante K vpliva časovna ločljivost intenzitetnih krivulj ter ali lahko mreža ohrani natančnost tudi, če je krivulja podana le na delu časovnega intervala. To je pomembno zlasti za realne eksperimente, kjer pogosto ni mogoče zajeti podatkov z visoko frekvenco ali v celotnem časovnem območju.

2.6.1 Vpliv časovne ločljivosti

Začeli smo z originalnimi signali, diskretiziranimi v 400 točkah na intervalu $[0, 1,2]$ s]. Nato smo signale interpolirali na manjše število točk: 200, 100, 50 in 25. S tem postopkom smo ustvarili nove nize vhodnih podatkov z različnimi časovnimi ločljivostmi, pri

čemer se je tudi velikost vhodne plasti mreže ustrezno spremenila. Potek učenja za različne časovne ločljivosti prikazuje slika 11.




Slika 11: Primerjava poteka učenja za signale z različnim številom časovnih točk. Nizka časovna ločljivost povzroči izgubo informacij o dinamiki intenzitetne krivulje.

Iz rezultatov sledi, da mreža nujno potrebuje dovolj gosto diskretizacijo, da lahko prepozna hitre spremembe v intenziteti, ki so ključne za rekonstrukcijo K . Premajhno število točk izniči pomembne značilnosti, kot so začetni nakloni ali lokalne maksimume, kar neposredno vpliva na napovedne zmogljivosti.

2.6.2 Učenje na časovnem izseku

V drugem delu naloge smo preizkusili, kako se mreža obnese, če učimo le na delu izvirnega časovnega signala. Iz 400-točkovnega signala smo izrezali interval $[0.12 \text{ s}, 1.2 \text{ s}]$, kar ustreza približno zadnjim 360 točkam celotnega časovnega poteka.

Na sliki 12 je prikazan potek učenja na izseku. Vidimo, da se mreža uspešno nauči povezave med okrnjenimi podatki in konstanto K , vendar je napaka nekoliko višja kot pri uporabi celotnega časovnega intervala.



Slika 12: Učenje na časovnem izseku [0.12 s, 1.2 s]. Model ohrani dobro konvergenco, vendar izgubi del začetnih informacij, kar je opazno pri majhnih vrednostih K .

2.7 Napovedovanje elastičnih konstant K_{11} in K_{33} pri različnih robnih pogojih

V tem delu naloge smo preučili, kako dobro lahko nevronska mreža napove elastični konstanti K_{11} in K_{33} iz simuliranih intenzitetnih krivulj za različne robne pogoje. V mapah DataK13_* so shranjeni numerični podatki za tri konfiguracije:

- **PP:** planarno–planarno sidranje,
- **PH:** planarno–homeotropno sidranje,
- **HH:** homeotropno–homeotropno sidranje.


Za vsako konfiguracijo smo ločeno učili isti model z dvema izhodnima nevronoma, ki hkrati napove K_{11} in K_{33} . Pred učenjem smo vhodne podatke normalizirali, izhodne pa preskalirali z 10^{-11} , kar omogoča stabilnejše učenje in manjšo numerično napako.

2.7.1 Rezultati za posamezne robne pogoje

Model smo trenirali posebej za vsak nabor DataK13_* in za vsak primer izračunali napake MAE za K_{11} in K_{33} . Poleg tega smo narisali dvodimenzionalne histograme primerjav *prava vrednost vs. napovedana vrednost* za vsako konstanto. Primeri grafov so prikazani na slikah 13, 14 in 15.


2.7.2 Interpretacija rezultatov

Planarno–planarno (PP). Ta konfiguracija v K_{11} daje najboljše rezultate. Razlog je, da PP pogoji ustvarijo bogat in izrazit profil $\theta(z, t)$.



Slika 13: Napovedovanje elastičnih konstant pri planarno–planarnih robnih pogojih.


Planarno–homeotropno (PH). Pri tej geometriji dobimo dobro napoved za K_{33} , medtem ko je napoved K_{11} bistveno bolj razpršena. Razlog je v asimetrični obliki začetnega profila, zaradi katere se raztezni del dinamike še vedno jasno izrazi, medtem ko upogibni del postane šibek in težje razločljiv.



Slika 14: Napovedovanje elastičnih konstant pri planarno–homeotropnih robnih pogojih.

Homeotropno–homeotropno (HH). Pri HH robnih pogojih so napovedi za obe konstanti slabe, še posebej za K_{11} . Intenzitetne krivulje so si zelo podobne, profil $\theta(z)$ pa ostaja blizu konstantnemu skozi celotno relaksacijo. To pomeni, da podatki ne vsebujejo dovolj informacij za ločevanje med K_{11} in K_{33} . Mreža zato ne more vzpostaviti

stabilne povezave med vhodom in izhodom, kar se kaže v široki in razpršeni porazdelitvi napovedi.



Slika 15: Napovedovanje elastičnih konstant pri homeotropno–homeotropnih robnih pogojih.

2.7.3 Pojasnilo horizontalne črte pri K_{33} PP in K_{11} HH

Horizontalna črta pomeni, da za dano robno konfiguracijo intenzitetne krivulje praktično ne nosijo informacije o določeni elastični konstanti, zato mreža zaradi odsotnosti razlik med vzorci za različne K napove skoraj konstantno vrednost.

2.8 Napovedovanje elastičnih konstant na eksperimentalnih podatkih

V zadnjem delu naloge smo uporabili izmerjene intenzitetne krivulje tekočega kristala 5CB, shranjene v mapi /ExpData. Datoteka vsebuje 30 eksperimentalnih potekov $I(t)$, izmerjenih v časovnem intervalu $[0, 1,95]$ s in diskretiziranih v 15 600 časovnih točkah. Uporabljena je bila celica debeline $10\ \mu\text{m}$ in kombinacija planarnega ter homeotropnega sidranja, skladno s konfiguracijo, za katero smo v prejšnjem delu analizirali podatke tipa PH.

Optične konstante ($n_o = 1,545$, $n_e = 1,740$) in rotacijska viskoznost tekočega kristala ($\gamma_1 = 0,098\ \text{Pas}$) so že vključene v numeričnem modelu, zato lahko eksperimentalne podatke neposredno primerjamo s simuliranimi krivuljami, uporabljenimi pri učenju modela.

2.8.1 Priprava eksperimentalnih podatkov


Zaradi zelo visoke časovne ločljivosti eksperimentalnih meritev (15 600 točk) smo intenzitetne signale najprej interpolirali na enako dolžino kot simulirane krivulje, da jih

lahko uporabimo kot vhod v že izurjeno nevronske mrežo. Signal je bil normaliziran in časovno preskaliran na interval $[0, 1, 2]$ s, ki ustreza simulacijskemu časovnemu oknu.


Za vsak eksperimentalni signal smo nato izračunali oceno elastičnih konstant K_{11} in K_{33} s pomočjo modelov, treniranih na podatkih DataK13_ph, saj ta robni pogoj ustreza poskusu (planarno–homeotropni).

2.8.2 Porazdelitev napovedanih konstant

Na slikah 16 in 17 so prikazane porazdelitve napovedanih vrednosti K_{11} in K_{33} za vseh 30 eksperimentalnih krivulj.



Slika 16: Porazdelitev napovedanih vrednosti K_{11} iz eksperimentalnih intenzitetnih krivulj.



Slika 17: Porazdelitev napovedanih vrednosti K_{33} iz eksperimentalnih intenzitetnih krivulj.

2.9 Razširitev nabora meritev z uporabo časovnih intervalov

Za izboljšanje napovedi lahko iz ene eksperimentalne intenzitetne krivulje vzamemo več krajših časovnih intervalov z različnimi začetnimi časi. Tak pristop je smiseln, ker relaksacija direktorja ni enaka skozi celoten čas: na začetku je hitrejša, kasneje počasnejša, zato vsak interval prinaša nekoliko drugačne informacije.


Na ta način dejansko dobimo več učnih primerov iz ene meritve, kar zmanjša vpliv šuma in lokalnih napak v posameznih delih signala. Ko povprečimo napovedi iz vseh intervalov, postaneta ocenjeni konstanti K_{11} in K_{33} bolj stabilni in manj razpršeni.

2.10 Povečanje števila meritev z izbiro več časovnih intervalov


V devetem delu naloge smo poskušali izboljšati napoved elastičnih konstant tako, da smo iz vsake eksperimentalne intenzitetne krivulje $I(t)$ vzeli več časovnih intervalov z različnimi začetnimi časi. Na ta način iz ene meritve dobimo več učnih primerov, ki vsi vsebujejo informacijo o isti materialni konstanti, vendar poudarjajo nekoliko različne dele časovne dinamike.

2.10.1 Vpliv na napoved elastičnih konstant

Po razdelitvi intenzitetnih krivulj na več prekrivajočih se časovnih intervalov smo za vsak interval posebej ocenili elastični konstanti K_{11} in K_{33} z isto nevronske mrežo kot prej. Na slikah 18 in 19 so prikazane porazdelitve napovedanih vrednosti, dobljenih iz celotnega ansambla intervalov.



Slika 18: Porazdelitev napovedanih vrednosti K_{11} , dobljenih iz več časovnih intervalov vsake eksperimentalne intenzitetne krivulje.



Slika 19: Porazdelitev napovedanih vrednosti K_{33} za ansambel časovnih intervalov.

Pri eksperimentalnih podatkih napovedane vrednosti K ne sovpadajo dobro s pričakovanimi. Razlog ni povsem jasan. Najverjetneje gre za razliko med simulacijami in dejanskimi signali (*domain shift*), dodatni šum in optične nepravilnosti v eksperimentu ter omejitve PH robnega pogoja, kjer je že pri simulacijah napoved manj zanesljiva. Možen je tudi manjši zamik zaradi skaliranja, vendar ga nismo uspeli dokončno potrditi.