

Univerza v Ljubljani
Fakulteta za *matematiko in fiziko*



Praktikum strojnega učenja v fiziki

Gručenje v hadronske curke

Študent:
Jurij Šumak
28242057

Profesor: prof. dr. Borut Paul Kerševan
Asistent: dr. Blaž Bortolato


AKADEMSKO LETO 2025/2026

Uvod


V tej nalogi obravnavamo problem identifikacije hadronskih curkov (ang. *jets*), ki nastanejo pri visokoenergijskih trkih protonov. Osredotočili smo se na dogodke, kjer nastane Higgsov bozon in razpade na par kvarkov b in $\bar{b}$. Cilj naloge je s pomočjo algoritmov gručenja (K-means, hierarhično gručenje in knjižnica *fastjet*) iz detektiranih končnih stanj hadronov rekonstruirati gibalno količino in maso Higgsovega bozona ($m_H^{exp} \approx 125,11$ GeV).

1 K-means algoritem na sintetičnih podatkih

Lastno implementacijo algoritma K-means smo najprej preizkusili na sintetičnih podatkih (mešanica dveh Gaussovih porazdelitev). Za določitev optimalnega števila gruč K smo uporabili *metodo komolca* (ang. *Elbow method*), kjer opazujemo vztrajnost (vsoto kvadratov razdalj) v odvisnosti od K .




(a): Metoda komolca pokaže optimalno vrednost $K = 2$.




(b): Rezultat lastne implementacije pri $K = 2$.

Slika 1: Preizkus na sintetičnih podatkih.


Poleg vrednosti $K = 2$ smo algoritem zagnali tudi za večje število gruč ($K \in \{3, 4, 5, 6\}$). Kot prikazuje slika 2, algoritem podatke matematično razdeli na podano število gruč, vendar takšna razdelitev umetno razdeli zgoščevanja podatkov v manjše podskupine.




(a): $K = 3$



(b): $K = 4$




(c): $K = 5$



(d): $K = 6$

Slika 2: Rezultati lastne implementacije K-means algoritma za vrednosti $K > 2$. Vidna je delitev homogenih oblakov točk.


Rezultate smo primerjali s štirimi drugimi algoritmi iz knjižnice `scikit-learn`: *KMeans*, *Gaussian Mixture Model (GMM)*, *Agglomerative Clustering* in *Spectral Clustering*. Vsi algoritmi so sintetične podatke pri $K = 2$ ločili v dve gruči z medsebojno primerljivimi rezultati. Model GMM je omogočil tudi izračun standardnega odklona obeh Gaussovih porazdelitev.



Slika 3: Primerjava rezultatov štirih algoritmov iz knjižnice `scikit-learn` za število gru $\check{c}$ $K = 2$.


2 Gru $\check{c}$ enje realnih podatkov in test infrarde $\check{c}$ e varnosti (IR)

Implementirani algoritem K-means smo, ob upoštevanju cilindri $\check{c}$ ne geometrije in peri-odi $\check{c}$ nih robnih pogojev za azimutni kot ϕ , uporabili na simuliranem dogodku razpada Higgsovega bozona. Za ustrezno uporabo v fiziki delcev mora biti algoritem infrarde $\check{c}$ e varen, kar pomeni, da dodajanje ali odvzem mehkih delcev (z majhno transversalno gibalno koli $\check{c}$ ino p_T) ne vpliva bistveno na kon $\check{c}$ ni rezultat. Kot prikazuje slika 4, ve $\check{c}$ ina delcev v analiziranem dogodku nosi majhen dele $\check{z}$ celotne energije.



Slika 4: Porazdelitev in kumulativni delež p_T . Delci z najmanjšim p_T nosijo majhen delež celotne energije dogodka.

Iz dogodka smo postopoma odstranjevali delce z najmanjšim p_T in merili spreminjanje rekonstruirane mase m_H . Zaradi nedeterministične narave algoritma smo za vsak korak izvedli več ponovitev ter določili povprečje in napako. Graf kaže, da pri odstranitvi manjšega števila delcev rezultat ostaja v začetnem območju zaupanja, ob večjem odstranjevanju pa vrednosti postanejo nestabilne.



Slika 5: Test infrardeče varnosti K-means algoritma. Zasenčeno območje predstavlja interval zaupanja (referenco) za primer z vsemi prisotnimi delci.

3 Hierarhično gručenje in vpliv parametra R

Sledila je implementacija determinističnega algoritma za hierarhično gručenje, ki preverja razdalje v ravnini (η, ϕ) in upošteva transversalno gibalno količino v odvisnosti od parametra p . Pri fiksnem parametru radija $R = 0.6$ smo za obravnavani dogodek dobili naslednje vrednosti:

- Algoritem anti- k_t ($p = -1$): $m_H = 124.04$ GeV (št. curkov: 84)
- Algoritem Cambridge-Aachen ($p = 0$): $m_H = 124.04$ GeV (št. curkov: 86)
- Algoritem k_t ($p = 1$): $m_H = 124.55$ GeV (št. curkov: 75)

Rezultati so blizu pričakovane mase 125.11 GeV.

Analiza vpliva parametra R


Pri algoritmu anti- k_t ($p = -1$) smo preverili odvisnost rekonstrukcije od parametra radija R :

- $R = 0.2 \Rightarrow m_H = 114.56 \text{ GeV}$ (169 curkov)
- $R = 0.6 \Rightarrow m_H = 124.04 \text{ GeV}$ (84 curkov)
- $R = 1.0 \Rightarrow m_H = 128.12 \text{ GeV}$ (51 curkov)
- $R = 1.5 \Rightarrow m_H = 144.99 \text{ GeV}$ (25 curkov)


Z zmanjšanjem parametra R (npr. na 0.2) algoritem iskanje prekine prej in ustvari ožje curke. Iz teh curkov izostanejo nekateri delci, ki pripadajo prvotnemu procesu, zaradi česar rekonstruirana invariantna masa podceni referenčno vrednost. Pri večjih vrednostih radija (npr. 1.5) so curki širši in zajamejo tudi prispevek ozadja (angl. *underlying event*), kar povzroči precenitev mase Higgsovega bozona.

4 Primerjava s knjižnico `fastjet`

Lastno Python implementacijo hierarhičnega gručenja smo primerjali s knjižnico `fastjet` pri uporabi algoritma k_t ($p = 1$). Pred neposredno primerjavo časa izvajanja smo za oba pristopa preverili infrardečo varnost z odstranjevanjem delcev z najnižjim p_T za različne vrednosti radija R .




(a): Lastna implementacija



(b): Algoritem `fastjet`


Slika 6: Prikaz infrardeče varnosti posameznega pristopa (algoritem k_t) pri različnih vrednostih R .

Grafa na sliki 6 in skupna primerjava na sliki 7 kažeta, da oba pristopa ohranita infrardečo varnost. Masa začne odstopati šele ob izločitvi večjega števila delcev, kar vključuje odstranjevanje tršega dela spektra dogodka.



Slika 7: Primerjava infrardeče varnosti (IR) med lastno implementacijo in algoritmom fast jet. Poteka krivulj kažeta ujemačo se trende.


Razlika med pristopoma je razvidna pri času izvajanja (slika 8). Algoritem fast jet (računska zahtevnost $\mathcal{O}(N \log N)$) se izvede nekaj redov velikosti hitreje od lastne implementacije, ki temelji na vektorizaciji.




Slika 8: Časovna zahtevnost v odvisnosti od števila odstranjenih delcev (logaritemska skala). Algoritem fast jet doseže krajše čase izvajanja ob primerljivih rezultatih.

5 Obdelava celotne množice dogodkov

V zadnjem delu smo z algoritmom *fastjet* (k_t , $R = 0.6$) obdelali celoten niz 10.000 dogodkov in rekonstruirali pripadajoče invariantne mase.



(a): Linearna skala



(b): Logaritemska skala

Slika 9: Spekter rekonstruiranih invariantnih mas Higgsovega bozona.

Določitev ocene mase in negotovosti

Iz logaritemskega histograma je razvidno, da porazdelitev izračunanih mas odstopa od Gaussove oblike in kaže asimetričen rep proti višjim energijam. Ta rep je posledica anomalij pri gručenju, ko se v curke zajame signal ozadja.

Upoštevanje osamelcev premakne aritmetično povprečje celotnega vzorca v desno; naivno izračunano povprečje tako znaša ≈ 191 GeV, kar vodi do precenitve mase.

Za ustrežnejšo oceno mase smo določili najpogostejšo vrednost (vrh oz. mode porazdelitve). Pripadajočo negotovost smo ovrednotili z izračunom standardnega odklona znotraj ožjega okna delcev okoli samega vrha (npr. ± 20 GeV okoli vrha), s čimer se omeji vpliv asimetričnega repa. Rezultat tega postopka poda končno oceno mase okoli 124 GeV, kar je blizu referenčni eksperimentalni vrednosti $m_H^{exp} = 125.11$ GeV.