

Univerza v Ljubljani
Fakulteta za *matematiko in fiziko*



Praktikum strojnega učenja v fiziki

VAE in nova fizika

Študent:
Jurij Šumak
28242057

Profesor: prof. dr. Borut Paul Kerševan
Asistent: dr. Blaž Bortolato


AKADEMSKO LETO 2025/2026

1 Uvod

Namen naloge je uporaba metod nenadzorovanega strojnega učenja za klasifikacijo podatkov in detekcijo anomalij. V prvem in drugem delu analiziramo ročno napisane številke iz podatkovne baze MNIST s pomočjo algoritma binarne mešanice in variacijskega avtoenkoderja (VAE). V tretjem delu uporabimo VAE kot orodje za iskanje nove fizike, natančneje za detekcijo dvocurkovnega signala razpada neznanega delca v ozadju standardnega modela na trkalniku LHC.


2 Binarna mešanica in MNIST

Slike števk dimenzije 28×28 pikslov obravnavamo kot 784-dimenzionalne vektorje, katerih komponente normaliziramo na interval $[0, 1]$. Za gručenje podatkov v 10 gruč (za 10 števk) uporabimo model binarne mešanice, kjer vsako gručo opišemo s produktom Bernoullijevih porazdelitev. Za iskanje optimalnih parametrov (deleži gruč π_j in povprečne vrednosti μ_j) smo implementirali algoritem pričakovanja-maksimizacije (EM). Zaradi majhnih verjetnosti in nevarnosti numeričnega preliva (ang. underflow) smo izračune izvedli v logaritemskem prostoru z uporabo stabilizacijskega trika s premikom eksponenta.




Slika 1: Potek konvergence EM algoritma. Prikazana je absolutna sprememba parametrov $\Delta\mu$ v odvisnosti od koraka. Učenje se stabilizira po približno 60 iteracijah.

Na sliki 1 je prikazan stabilen in monoton padec napake med učenjem. Po zaključenem učenju algoritem vrne 10 vektorjev μ_j , ki predstavljajo povprečne vrednosti posameznih gruč (slika 2). Pomanjkljivost binarne mešanice je, da pogosto preplete vizualno podobne številke (npr. 4, 7 in 9) in izgubi redkejša številke (npr. 5). S temi naučenimi porazdelitvami lahko generiramo nove številke z žrebanjem iz binomske porazdelitve, kar je prikazano na sliki 3. Z večanjem parametra n se generirane številke bolj izoblikujejo.



Slika 2: Vizualizacija naučenih parametrov μ^j binarne mešanice, ki predstavljajo povprečne številke posameznih gruč.


Generirane (izžrebane) številke s povečevanjem parametra n



Slika 3: Naključno generiranje števk za izbrane gručice ob uporabi binomske porazdelitve pri različnih vrednostih parametra n .


3 Variacijski avtoenkoder (VAE) in MNIST

V drugem delu smo implementirali variacijski avtoenkoder v knjižnici Keras. VAE je sestavljen iz enkoderja in dekoderja (uporabili smo eno skrito plast s 64 nevroni), med katerima je vzorčevalna plast z reparametrizacijskim trikom. Ta omogoča zvezno odvajanje in učenje modela s povratnim razširjanjem napake (ang. backpropagation). Latentni prostor je dvodimenzionalen. Cenovna funkcija je sestavljena iz rekonstrukcijske napake (binarna navzkrižna entropija) in Kullback-Leiblerjeve (KL) divergence, ki sili latentne porazdelitve proti standardni normalni porazdelitvi $\mathcal{N}(0, 1)$.



Slika 4: Preslikava testne množice MNIST v 2D latentni prostor. Vsaka točka predstavlja eno sliko, barve označujejo pripadajočo številko.

Slika 4 prikazuje porazdelitev testne množice v 2D latentnem prostoru. Sorodne številke se gruči skupaj. Orientacija celotnega prostora (zrcaljenja ali zasuki) se med posameznimi zagoni učenja razlikuje, saj je ciljna porazdelitev (zaradi KL divergence) rotacijsko simetrična, začetne uteži modela pa so naključne. Model smo preverili tudi z generiranjem novih števk znotraj domene $[-4, 4]$ latentnega prostora (slika 5). Zvezno prehajanje med števki potrjuje primernost VAE kot generativne metode.




Slika 5: Generirane številke iz enakomerne 2D mreže v latentnem prostoru (območje od -4 do 4).

4 Mase neznanih delcev

V tretjem delu obravnavamo iskanje resonančnega vrha v invariantni masi, ki ustreza fiktivnemu procesu razpada delca Z' na X in Y . Podatki simulacije vključujejo lastnosti hadronskih curkov (mase m_j , spremenljivke τ_2/τ_1 , τ_3/τ_2 in massdrop). Model VAE smo učili zgolj na teh spremenljivkah, brez vnosa invariantne mase m_{inv} .


Za uspešno učenje smo podatke najprej transformirali z orodjem QuantileTransformer, kar je izenačilo porazdelitve na intervalu $[0, 1]$ (slika 6). Arhitektura VAE je obsegala tri skrite plasti s 64 nevroni, enodimenzionalni latentni prostor in uporabo optimizatorja adadelta.




Slika 6: Porazdelitev prvih štirih spremenljivk testnih podatkov pred (zgoraj) in po (spodaj) transformaciji z QuantileTransformer.

4.1 Analiza latentnega prostora in ROC klasifikatorji

Zanimivo je opaziti odziv VAE modela na delež signala. Pri realističnem (majhnem) deležu signala model večinsko ozadje, ki predstavlja normo, preslika v središče porazdelitve $\mathcal{N}(0, 1)$, redek signal pa potisne na robove kot anomalijo. V primeru testnih podatkov H, kjer je delež signala nerealistično visok (10 %), gosta gruča signala prevlada. Posledično model postavi signal v središče latentnega prostora ($z \approx 0$), široko ozadje pa razprši na robove. Klasifikator z_{mean}^2 se izkaže za izjemno učinkovit v obeh režimih, le smer reza je obrnjena. To potrjuje tudi slika 8, kjer klasifikatorja dosegeta visoko površino pod krivuljo (AUC).




Slika 7: Porazdelitev signala in ozadja (testni podatki H) v 1D latentnem prostoru. Zaradi velike količine signala se ta nahaja v središču Gaussovega zvona ($z_{mean}^2 \approx 0$), ozadje pa je izrinjeno na robove.



Slika 8: Krivulje ROC in odvisnost $1/\text{FPR}$ od TPR za izbrane klasifikatorje v 1D latentnem prostoru.


4.2 Določanje mas delcev na testnih podatkih in podatkih črne škatle

Metodo smo validirali tako, da smo izločili območje latentnega prostora, kjer prevladuje signal, in narisali histograme za masi curkov ter celotno invariantno maso. Za testne podatke H smo, v skladu z zgoraj omenjenim pojavom, izločili dogodke z najnižjimi vrednostmi z_{mean}^2 (središče porazdelitve). Maso smo odčitali neposredno iz pozicije vrhov. Slika 9 za testne podatke H jasno izriše vrhove okoli znanih vrednosti $m_X = 500$ GeV, $m_Y = 100$ GeV in $m_{Z'} = 3500$ GeV.



Slika 9: Histogrami mas za 500, 1000 in 2000 dogodkov signala pri testnih podatkih H. Vrhovi jasno določajo mase delcev X , Y in Z' .

Isti postopek smo nato uporabili na podatkih črne škatle. Ker je pri teh podatkih delež signala majhen, smo model uporabili kot iskalnik anomalij in izločili dogodke z najvišjimi vrednostmi z_{mean}^2 (robovi porazdelitve). S pomočjo omejitve opazovanega območja invariantne mase na interval $[3600, 4000]$ GeV smo izrisali histograme najbolj anomalnih dogodkov (slika 10).



Slika 10: Histogrami mas za podatke črne škatle. Z uporabo naučenega klasifikatorja in izrezom anomalij na robovih latentnega prostora lociramo iskan signal ozadja.

Iz histogramov črne škatle na sliki 10 lahko določimo mase neznanih delcev. Vrh prvega curka se nahaja v okolici $m_{j1} \approx 600 - 700$ GeV, vrh drugega curka izrazito stoji v okolici $m_{j2} \approx 400$ GeV. Invariantna masa celotnega dogodka je zaradi nizke statistike bolj razpršena; z nekaj domišljije jo lahko prepoznamo v območju $m_{inv} \approx 3,70 - 3,85$ TeV.