

UNIVERZA V LJUBLJANI
FAKULTETA ZA MATEMATIKO IN FIZIKO
Oddelek za fiziko

7. naloga: VAE in nova fizika

Praktikum strojnega učenja v fiziki,
Fizika, 2. stopnja, 2. letnik

Avtor: Kevin Jaksetič, vpisna številka: 28222050
Predavatelj pri nalogi: prof. dr. Jernej Fesel Kamenik
Asistent pri nalogi: Blaž Bortolato

Študijsko leto 2023/2024


Kazalo

1	Binarna mešanica in MNIST	1
2	VAE in MNIST	3
3	VAE in mase neznanih delcev	4
3.1	Podatki črne škatle	13

1 Binarna mešanica in MNIST

Ukvarjamo se s klasifikacijo in generacijo števk iz MNIST podatkov z uporabo binarne mešanice. Podatkovno zbirko MNIST sestavljajo slike števk 28×28 pikslov, vsak piksel pa lahko zavzame celoštevilsko vrednost med 0 in 255. Zato podatke pred pričetkom analize normiramo na interval med 0 in 1.

Binarno mešanico sem implementiral po navodilih in jo učil 100 korakov. Potek učenja je prikazan na sliki 1. Vidimo, da se sprva uteži naglo spreminjajo, nato pa učenje poteka počasi.




Slika 1: Spreminjanje parametrov binarne mešanice po korakih.

Sedaj lahko narišemo nekaj nizov μ^j , ki predstavljajo slike števk kot jih dojema binarna mešanica. Na sliki 2. Rezultati niso slabi vendar potrebujejo izboljšavo, saj zglada da je mešanice prepletla števk 9 še s 7 in 4. Števk 5 smo popolnoma izgubili.


Nazadnje v tem delu želimo še generirati nove števk. Nekaj primerov je prikazanih na sliki 3.

Slike števil v μ_j



Slika 2: Števke predstavljene z nizi μ^j . Številka 9 se pojavi trikrat in zleđa da jo je mešanica prepletla s 7 in 4. Ničla se pojavi dvakrat, število 5 pa smo popolnoma izgubili.


Žrebane številke




Slika 3: Žrebanje novih števk se izboljšuje z večanjem binomskega n .

2 VAE in MNIST

V tem delu implementiramo VAE kot opisujejo navodila ter ga učimo do 100 epoh na 60000 podatkih baze MNIST. Na sliki 4 si oglejmo kako je enkoder ločil številke v 2D latentnem prostoru. Model ima največje probleme s petkami, osemkami in trojkami, najlepše pa loči enke in nule. Na sliki 5 vidimo generacijo novih števk z naučenim modelom.



Slika 4: Porazdelitev števk v latentnem prostoru. Podobne številke so v latentnem prostoru blizu skupaj, npr. 3 in 8, 5 in 6, 1 in 7, ipd. V podatkih MNIST so si zelo podobne številke 9, 7 in 4. Bolj različne številke so v latentnem prostoru bolj narazen in jih lepše ločimo.



Slika 5: Generirane slike na izbrani mreži v latentnem prostoru s slike 4. Veliko števk je lepo generiranih, problemi so samo s tistimi na sredini kjer se prepleta več podobnih števk.

3 VAE in mase neznanih delcev

V nadaljevanju uporabimo VAE za razločevanje dogodkov signala od dogodkov ozadja. VAE slika podobne vhodne podatke blizu skupaj v latentnem prostoru, torej je smiselno pričakovati, da bodo dogodki signala v latentnem prostoru lokalizirani. Tipično je število dogodkov signala veliko manjše kot dogodkov ozadja, kar pomeni, da bo VAE boljše rekonstruiral dogodke iz ozadja. Vemo še, da če dogodki ozadja in signala pripadajo dovolj različnim porazdelitvam, je smiselno tudi pričakovati, da bodo dogodki signala v latentnem prostoru lokalizirani na robovih porazdelitve dogodkov ozadja. Če obstaja klasifikator v latentnem prostoru za katerega je znano, kje se pojavijo dogodki signala, ga lahko uporabimo za izluščanje lastnosti signala ter generacijo novih dogodkov signala.


V nadaljevanju se bomo ukvarjali s procesom trka dveh protonov, ki ustvarita fiktiven delec Z' . Ta razpade na dva neznana produkta X in Y . Oba nato razpadeta na znane delce ter s tem ustvarita curek delcev. Oba curka detektiramo. V primeru, ko protona ne ustvarita delca Z' detektiramo ozadje. Na tak način imamo dogodke signala (protona ustvarita Z) in dogodke ozadja.

Uporabili bomo 2 tipa podatkov, testne podatke in podatke črne škatle. Pri testnih podatkih poznamo mase delcev X, Y, Z' in kateri dogodki so signal in ozadje, medtem ko pri podatkih črne škatle ne poznamo mas in ne vemo kateri dogodki predstavljajo signal in ozadje. Cilj je pripraviti metodo določanja mas delcev X, Y in Z' z uporabo VAE na testnih podatkih in nato jo preizkusiti na podatkih črne škatle.


Testni podatki so pripravljeni za primera, ko je razmerje med številom dogodkov signala in ozadja $S/B = 10\%$ (H) in, ko je to razmerje $S/B = 0.1\%$ (L). Obravnavamo 1100000 dogodkov, za vsakega poznamo 8 podatkov, 4 za vsak hadronski curek. Za prvi curek poznamo $m_{j1}, (\tau_2/\tau_1)_1, (\tau_3/\tau_2)_1$ in m_{dj1} , kjer je prvi podatek masa hadronskega curka z največjo transversalno gibalno količino, druga in tretja količina sta N-subjettiness, in je zadnja količina vsota massdropov.

Oglejmo si podatke za 10% signala na slikama 6 in 7. Po transformaciji se dogodki preslikajo v enakomerno porazdelitev na intervalu $[0,1]$. Te podatke uporabimo za trening VAE (kakršen je opisan v navodilih). Pred tem pa še preverimo delovanje inverzne transformacije na slikama 8 in 9. Transformacija ni popolna, velikosti se nekoliko popačijo, vendar vsaj centri signalov ostanejo približno enaki.


VAE natreniramo na transformiranih podatkih za npr. tri poskuse in shranimo dobljene uteži. Na slikama 10 in 11 je prikazana porazdelitev signalov v latentnem prostoru. Vidimo, da se glede na z_{mean} in z_{mean}^2 signal nahaja na robu latentnega prostora.




Slika 6: Izvirne (zgoraj) in transformirane (spodaj) spremenljivke za prvi curek (H).




Slika 7: Izvirne (zgoraj) in transformirane (spodaj) spremenljivke za drugi curek (H).




Slika 8: Inverzno transformirani podatki in napaka glede na originalne, za prvi curek.



Slika 9: Inverzno transformirani podatki in napaka glede na originalne, za drugi curek.




Slika 10: Podatki v latentnem prostoru za 3 poskuse na podatkih H.




Slika 11: Podatki v latentnem prostoru za 3 poskuse na podatkih L.

Poglejmo si še uspešnost modela s pomočjo ROC krivulj in ustreznega AUC. Ti so prikazani na slikama 12 in 13, kot tudi odvisnost $1/\text{FPR}$ od TPR. Klasifikator z_{mean}^2 je bil najuspešnejši. To je verjetno posledica tega, da je signal zanj najbolj na robu latentnega prostora.




Slika 12: Od leve proti desni so prikazane uspešnosti treh natreniranih VAE za podatke H. Zgoraj so prikazane ROC krivulje in izračunani AUC, spodaj pa odvisnost $1/\text{FPR}$ od TPR.




Slika 13: Od leve proti desni so prikazane uspešnosti treh natreniranih VAE za podatke L. Zgoraj so prikazane ROC krivulje in izračunani AUC, spodaj pa odvisnost $1/\text{FPR}$ od TPR.

Sedaj razvrstimo netransformirane podatke za invariantno maso, m_{j1} in m_{j2} po naraščajoči ali padajoči vrednosti klasifikatorja z največjim AUC (za nas z^2_{mean}) tako, da bo večina dogodkov signala na začetku seznama. Vzamemo prvih $n = [500, 1000, 2000]$ dogodkov iz tega seznama in poskusimo določiti maso neznanega delca in masi obeh produktov z negotovostjo. To storimo s prilagajanjem funkcije Crystall Ball. Problem je zelo nestabilen,


vendar lahko z dovolj igranja z začetnimi parametri pridemo do optimalnih parametrov in s tem mase ter širine porazdelitve (σ iz funkcije). Rezultati za primera H in L so prikazani na slikah 14, 15 in 16. Iz podatkov H smo izračunali $m_{j1} = (500 \pm 20)$ GeV, $m_{j2} = (98 \pm 5)$ GeV in $m_{\text{inv}} = (3470 \pm 100)$ GeV. Iz podatkov L pa smo dobili $m_{j1} = (500 \pm 20)$ GeV, $m_{j2} = (98 \pm 5)$ GeV in $m_{\text{inv}} = (3470 \pm 100)$ GeV. Izračuni za podatke L so bili še dosti bolj nestabilni, vendar nam je z drugim navedenim poskusom uspelo izračunati vse mase. Dobili smo vrednosti: $m_{j1} = (300 \pm 70)$ GeV, $m_{j2} = (100 \pm 40)$ GeV in $m_{\text{inv}} = (2620 \pm 40)$ GeV. Razen m_{j2} se rezultati ne ujemajo s tistimi od H, poleg tega pa je invariantna masa bolj stabilno določena v prvem navedenem poskusu...odvisno kako se posreči. Ob upoštevanju več poskusov je algoritem vsekakor koristen za napovedovanje mase.



Slika 14: Napovedane mase curkov in invariantne mase, za podatke H.




Slika 15: Napovedane mase curkov in invariantne mase, za podatke L. Problem je nestabilen in za maso prvega curka sploh ne dobimo legitimnega rezultata. Zato pa nam je uspelo v nekaj drugih poskusih.



Slika 16: Napovedane mase curkov in invariantne mase, za podatke L, za 2. poskus. Tu nam je mase uspelo določiti, sicer pa se samo vrednost m_{j2} ujema z rezultati H.

Rekonstrukcija podatkov


Poglejmo si, kako dobro model rekonstruira podatke. Na vhodnih podatkih uporabimo enkoder in dekoder. Na koncu moramo dobljen izhod še inverzno transformirati. Dobimo rezultat s slike 17 in vidimo, da je spektre pri rekonstrukciji porezalo. Je pa vsaj vrh signalov ostal na približno pravih mestih.



Slika 17: Rekonstrukcija podatkov H za oba curka. Očitno se ne ujema s podatki s slik 6 in 7. Vrhovi signalov ostajajo približno enaki, vendar je spektre pri rekonstrukciji porezalo.


3.1 Podatki črne škatle

VAE smo natrenirali na transformiranih podatkih črne škatle in dobili porazdelitve v latentnem prostoru s slike 18. Iz vsega kar smo se do sedaj naučili lahko sklepamo, da je v našem primeru z_{mean}^2 optimalni klasifikator, zato ga uporabimo za napovedi mas.



Slika 18: Porazdelitve v latentnem prostoru so iste oblike kot prejšnje iz učnega seta.

Rezultati prilagajanja funkcije Crystal Ball so prikazani na sliki 19. Vidimo da se izračunane vrednosti ponovno razlikujejo od tistih izračunanih prej. Ostre špice krivulj nam namigujejo o nestabilnosti prilagajanja krivulje, zato lahko morda sklepamo da podatki črne škatle vsebujejo več ozadja kot podatki H (kar bi bilo tudi pričakovano).



Slika 19: Napovedane mase curkov in invariantne mase za podatke črne škatle.